


UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY




PODPORA INTELIGENTNÉHO RIADENIA
ENERGETICKÝCH SIETÍ
DIPLOMOVÁ PRÁCA

2023

BC. OMAR AL-SHAFE'I

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



PODPORA INTELIGENTNÉHO RIADENIA ENERGETICKÝCH SIETÍ

DIPLOMOVÁ PRÁCA

Študijný program:	Informatika
Študijný odbor:	Aplikovaná informatika
Školiace pracovisko:	Katedra aplikovanej informatiky
Školiteľ:	prof. RNDr. Mária Lucká, PhD.

Bratislava, 2023

Bc. Omar Al-Shafe'i



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Omar Al-Shafe'i
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Podpora inteligentného riadenia energetických sietí
Support for intelligent management of smart energy networks

Anotácia: Stabilita inteligentnej energetickej siete a zabezpečenie dodávok elektrickej energie môže byť potenciálne narušená integráciou obnoviteľných zdrojov energie (napr. fotovoltických panelov), veľkých úložísk energie (batérií), ale aj významným rozvojom elektromobility. Tieto nové prvky sa v súčasnosti v čoraz väčšej miere stávajú súčasťou moderných inteligentných energetických sietí a preto ich integrácia do celej sústavy sa stala mimoriadne dôležitou. Pôvodne jednosmerná sieť, kde sa energia od veľkých výrobcov elektriny dodávala spotrebiteľom, sa postupne mení na obojsmernú sieť, v ktorej sa mnohí odberatelia - vďaka obnoviteľným zdrojom - stávajú súčasne aj drobnými výrobcami – prosumeri. Kvôli garancii stability celej sústavy a zabezpečeniu minimálnej ceny bolo potrebné vytvoriť tzv. agregátorov flexibility, ktorým účastníci siete môžu poskytnúť svoju flexibilitu. Pod flexibilitou pritom rozumieme práva (1) na odber vyrobenej alebo uskladnenej elektrickej energie (napr. z fotovoltiky, batérie alebo elektromobilu) v určitom čase a (2) obmedzenie spotreby (napr. vypnutie kúrenia). Navrhnete a overte model práce agregátora flexibility, ktorý vďaka inteligentným algoritmom a dátovej analýze dokáže optimalizovať tok energie, zabezpečiť stabilné dodávky energie a minimalizovať náklady spotrebiteľov. Svoje riešenie obmedzte pre vybraný typ prosumerov/spotrebiteľov. Použite pritom vhodné optimalizačné metódy, predovšetkým metódy strojového učenia. Svoje riešenie implementujte a porovnajte s existujúcimi riešeniami na dostupných dátach.

Literatúra:

1. Li, T., Sun, B., Chen, Y., Ye, Z., Low, S. H., & Wierman, A. (2020). Real-time Aggregate Flexibility via Reinforcement Learning. 1–17. <http://arxiv.org/abs/2012.11261>
2. Fernando Lezama, Joao Soares, Bruno Canizes, Zita Vale: Flexibility management model of home appliances to support DSO requests in smart grids, Sustainable Cities and Society, Volume 55, 2020, ISSN 2210-6707, <https://doi.org/10.1016/j.scs.2020.102048>
3. Tongxin Li and Bo Sun and Yue Chen and Zixin Ye and Steven H. Low and Adam Wierman: Learning-Based Predictive Control via Real-Time Aggregate Flexibility, IEEE Transactions on Smart Grid, 12 (6), 2021, 97–4913, <https://doi.org/10.1109%2Ftsg.2021.3094719>.



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

4. Steve Wattam: Artificial intelligence and machine learning approaches to energy demand-side response: A systematic review, Renewable and Sustainable Energy Reviews, Volume 130, 2020, 109899, ISSN 1364-0321, <https://doi.org/10.1016/j.rser.2020.109899>.

Vedúci: prof. RNDr. Mária Lucká, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.
Dátum zadania: 13.12.2022

Dátum schválenia: 13.12.2022

prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

.....
šľudent

.....
vedúci práce

Pod'akovanie: Chcel by som pod'akovať mojej školiteľke za cenné rady počas tvorby diplomovej práce.

Abstrakt

Slovenský abstrakt v rozsahu 100-500 slov, jeden odstavec. Abstrakt stručne sumarizuje výsledky práce. Mal by byť pochopiteľný pre bežného informatika. Nemal by teda využívať skratky, termíny alebo označenie zavedené v práci, okrem tých, ktoré sú všeobecne známe.

Kľúčové slová: jedno, druhé, tretie (prípadne štvrté, piate)

Abstract

Abstract in the English language (translation of the abstract in the Slovak language).

Keywords:

Obsah

Úvod	1
1 Opis problému	3
1.1 Súčasný stav riešenej problematiky.	3
1.2 Formulácia problému.	5
2 Cieľ práce	7
2.1 Úlohy agregátora flexibility	7
3 Návrh riešenia	9
3.1 Smoothed Least Laxity First.	9
3.2 Penalised Predictive Control.	10
3.2.1 Učenie a testovanie	11
4 Implementácia	12
4.1 Model predictive control	12
5 Experimenty	13
5.1 Ukážka vstupných dát ACN-Data	13
5.2 Využité technológie	14
5.2.1 Balík acnportal.	14
5.2.2 Architektúra simulátora ACN-Sim	15
5.2.3 Balík adacharge.	16
5.2.4 Balík acnportal-experiments.	16
5.2.5 Balík stable-baselines3.	16
5.3 Konfigurácia a obmedzenia nabíjacích sietí	17
5.3.1 Typy nabíjania.	17
5.3.2 Infraštruktúra nabíjacej stanice.	18
5.4 Prvý experiment	18
5.4.1 Vstupné dáta	18
5.4.2 Hardverové nastavenia	19
5.4.3 Výsledky	19

<i>OBSAH</i>	v
5.5 Druhý experiment	19
5.5.1 Vstupné dáta	19
5.5.2 Nastavenia	20
5.5.3 Výsledky	20
5.6 Tretí experiment	20
Záver	21
Príloha A	24
Príloha B	25

Zoznam obrázkov

1.1	Vplyv vedomostí o budúcich príchodoch elektromobilov na výkonnosť plánovacieho algoritmu.	4
2.1	Systém toku energie a ziskov.	8
5.1	Ukážka vstupných dát ACN-Data	13
5.2	Schéma acnportal.	15
5.3	Architektúra simulátora ACN-Sim.	15
5.4	Typy nabíjania elektromobilov	17
5.5	Porovnanie	19

Zoznam tabuliek

1.1	Notácia.	5
-----	------------------	---

Úvod

S neustále pribúdajúcim množstvom elektrických vozidiel na trhu sa zväčšuje množstvo elektrickej energie, ktorú treba dodať elektrickým vozidlám. Môže nastať situácia, že kapacity jednotlivých nabíjacích staníc nebudú stačiť pre nabitie každého elektrického vozidla požadovaným množstvom energie. Preto sa postupne aj odberatelia elektrickej energie stávajú výrobcami elektrickej energie pomocou obnoviteľných zdrojov. Tým sa jednosmerná sieť, v rámci ktorej veľkí výrobcovia dodávajú energiu spotrebiteľom, mení na obojsmernú sieť, kde odberatelia, ktorí sú výrobcami elektrickej energie môžu poskytovať za týmto účelom podporné služby.

Riešením týchto problémov sú inteligentné takzvané smart siete. Tieto siete obsahujú agregátor flexibility, ktorému poskytujú flexibilitu používatelia nabíjacej siete. To znamená, že agregátor flexibility má právo riadiť odber elektrickej energie pre elektrické vozidlá a prispôbovať ho podľa potrieb a podľa podmienok nabíjacej siete. Používatelia, ktorí sú tiež výrobcami elektrickej energie z obnoviteľných zdrojov, môžu poskytovať podporné služby prostredníctvom agregátora flexibility (takýchto používateľov nazývame prosumeri), a to tým, že napríklad agregátor flexibility od nich kúpi energiu. Používatelia v takýchto sieťach môžu nastaviť svoje preferencie, ako napríklad preferovaný čas nabíjania a množstvo požadovanej energie. Agregátor flexibility vie následne pomocou inteligentných algoritmov optimalizovať tok energie. Využíva pritom optimalizačné metódy alebo metódy strojového učenia (napr. neurónové siete). Agregátor flexibility tiež minimalizuje cenu elektrickej energie pre jej spotrebiteľov tým, že nakupuje elektrickú energiu v čase, keď je najlacnejšia a predáva elektrickú energiu v čase, keď je najdrahšia.

Cieľom tejto práce je overiť model práce agregátora flexibility, ktorý vie pomocou inteligentných algoritmov a dátovej analýzy optimalizovať tok energie, zabezpečiť stabilné dodávky energie a zároveň minimalizovať náklady používateľov elektrických vozidiel. Porovnáme naše riešenia tohoto problému s inými doterajšími riešeniami. [9]

V prvej kapitole rozoberieme východiská pri tvorbe nášho modelu agregátora flexibility, opíšeme existujúce riešenia a aj obmedzenia infraštruktúry pri nabíjaní elektrických vozidiel. V druhej kapitole predstavujeme model práce nášho agregátora flexibility a spomíname inteligentné algoritmy, ktoré sme v našom modeli použili.

V tretej kapitole overujeme model práce agregátora flexibility, kde porovnáваме naše riešenie s existujúcimi riešeniami, a to vzhľadom na pomer dodanej energie, množstvo dodanej

energie, cenu dodanej energie a počet výmen elektrických vozidiel. Vstupné dáta o elektrických vozidlách získavame z nabíjacích staníc pre elektrické vozidlá: stanica ACN a stanica JPL. Výstupom našej implementácie je optimálny plán nabíjania elektrických vozidiel vzhľadom k dodanej energii. V našej implementácii sa snažíme počet výmen elektrických vozidiel minimalizovať, keďže to často vedie k nespokojnosti používateľov elektrických vozidiel.

1 Opis problému

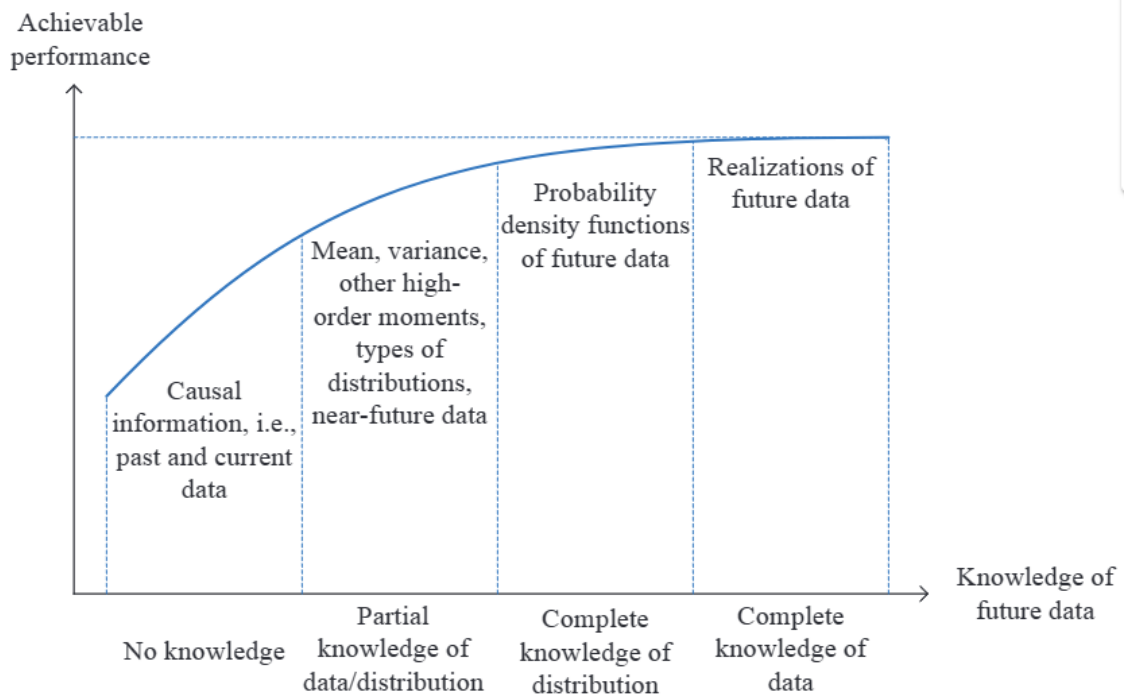
V tejto kapitole formulujeme problém, ktorý riešime a hovoríme aj o súčasnom stav jeho riešenia. Spomíname viacero prístupov od autorov, ktoré tento problém riešia.

1.1 Súčasný stav riešenej problematiky.

Množstvo elektrických vozidiel (okrem dvojkolových a trojkolových) sa má podľa predikcií [3] zvýšiť od takmer 30 miliónov áut v roku 2022 po 240 miliónov áut roku 2030. V takom scenári by elektrické vozidlá tvorili viac ako 10% zo všetkých cestných vozidiel. [3]

Veľ a nabíjacích staníc dnes neriadi nabíjanie elektrických vozidiel, čo znamená, že nabíjačky nabíjajú elektrické vozidlá najväčším povoleným množstvom energie. Neriadené nabíjanie väčšieho množstva elektrických vozidiel už nebude použiteľné, lebo neberie do úvahy obmedzenia infraštruktúry nabíjacej siete na energiu. [9] Pokroky v architektúre nabíjacej siete a v plánovaní nabíjania elektrických vozidiel umožnia nabíjanie väčšieho množstva elektrických vozidiel za prijateľnú cenu a bez priveľkej záťaže na infraštruktúru nabíjacej siete. Súhrnne tieto pokroky voláme inteligentné (aj adaptívne) nabíjanie. [10, 6]

Cieľom tejto práce je nájsť taký plán nabíjania elektrických vozidiel v nabíjacej stanici vďaka ktorému dokáže agregátor flexibility optimalizovať tok energie, zabezpečiť stabilné dodávky energie a minimalizovať náklady spotrebiteľov na energiu pri rešpektovaní obmedzení infraštruktúry nabíjacej siete. Správny plán nabíjania dokáže oddialiť náklady na vylepšenia infraštruktúry nabíjacej siete a pritom spĺňať stanovené vlastnosti. Algoritmy na nabíjanie elektrických vozidiel (plánovacie algoritmy) delíme do dvoch skupín online a offline. Offline algoritmy na plánovanie nabíjania elektrických vozidiel potrebujú všetky informácie o budúcich príchodoch elektrických vozidiel. Online algoritmy používajú informácie len o príchodoch elektrických vozidiel po aktuálny čas na plánovanie nabíjania elektrických vozidiel.



Obr. 1.1: Graf z článku [13], ktorý ilustruje vplyv vedomostí o budúcich príchodoch elektrických vozidiel na výkonnosť plánovacieho algoritmu.

Bežné online plánovacie algoritmy (ako napríklad Earliest Deadline First, Least Laxity First) vieme použiť, aby sa infraštruktúra nabíjacej siete nepreťažovala, ale nedokážu vyprodukovať plán nabíjania elektrických vozidiel, ktorý napríklad minimalizuje náklady spotrebiteľov. [10, 1] Výskumníci dokázali nájsť plán nabíjania s týmito vlastnosťami vďaka tomuto prístupu:

Prístup	Článok
Model Predictive Control (MPC)	[6]
Učenie posilňovaním	[11]
Dynamické programovanie	[17]

Autori článku [6] implementujú online plánovací algoritmus Model Predictive Control, ktorý je schopný riešiť náš cieľ práce pomocou metód konvexnej optimalizácie. Plánovací algoritmus MPC popísaný v tomto článku sa odlišuje od ostatných MPC algoritmov tým, že uvažuje obmedzenie trojfázovej nevyváženej infraštruktúry nabíjacej siete a neideálne správanie batérie elektrického vozidla. Najpodstatnejší rozdiel je v tom, že je možné zadať viacero cieľov systémových operátorov v účelovej funkcii v MPC algoritme, ktoré rieši algoritmus MPC pomocou metód konvexnej optimalizácie. Porovnávanie výkonnosti algoritmov vykonávajú na trojfázovej nevyváženej infraštruktúre nabíjacej stanice Caltech ACN

so vstupnými dátami z článku [8].

V [17] autori implementujú dvojfázový aproximačný algoritmus dynamického programovania s cieľom dodať elektrickým vozidlám ich požadovanú energiu a minimalizovať náklady za nabíjanie elektrických vozidiel na parkoviskách komerčných budov. Vstupné dáta o prichádzajúcich elektrických vozidlách modelujú na základe Poissonovej distribúcie. Na zistenie funkčnosti ich algoritmu porovnali ceny nabíjania pri nabíjaní pomocou ich algoritmu s cenou nabíjania pomocou bežného aproximačného algoritmu. Zistili, že ich algoritmus v porovnaní s bežným aproximačným algoritmom dynamického programovania dosahuje v priemere o 2.5% nižšiu cenu nabíjania elektrických vozidiel.

V tabuľke nižšie popisujeme notáciu, ktorú používame v tejto práci.

V	Množina elektrických vozidiel.
V_k	Množina aktívnych (pripojených) elektrických vozidiel na nabíjacej stanici v čase k .
K	Množina časov ($K := \{1, 2, \dots\}$).
δ	Dĺžka časového intervalu (jednotka: minúty).
a_i	Čas príchodu (pripojenia) elektrického vozidla i normalizovaný na základe množiny časov K ($a_i \in K$).
d_i	Čas odchodu (odpojenia) elektrického vozidla i normalizovaný na základe množiny časov K ($d_i \in K$).
e_i	Požadovaná energia elektrického vozidla i (jednotka: kWh).
$e_i(k)$	Zostávajúca požadovaná energia elektrického vozidla i v čase k .
$d_i(k)$	Zostávajúci čas nabíjania elektrického vozidla i v čase k .
$r_i(k)$	Rýchlosť nabíjania elektrického vozidla i v čase k (jednotka: kWh).
\bar{r}_i	Maximálna rýchlosť nabíjania elektrického vozidla i (jednotka: kWh).
$P(t)$	Kapacita nabíjacej siete na energiu.
$[x]^+$	Projekcia x do množiny reálnych nemínusových čísel \mathbb{R}^+ .
$[x]_a^b$	Projekcia x na interval $[a, b]$.

Tabuľka 1.1: Notácia.

1.2 Formulácia problému.

Model systému, v ktorom problém riešime, pozostáva z jednej nabíjacej stanice, ktorá obsluhuje množinu elektrických vozidiel V . Používame model systému s diskretným časom. V modeli systému s diskretným časom je čas $k \in K$ rozdelený do časových intervalov s rovnakými dĺžkami δ . Každé prichádzajúce elektrické vozidlo $i \in V$ sa pripojí na nabíjačku na nabíjacej stanici v čase a_i s požadovanou energiou e_i a s časom odchodu d_i a maximálnou rýchlosťou nabíjania batérie \bar{r}_i . Nabíjacia stanica obsluhuje v čase $k \in K$ všetky aktívne elektrické vozidlá $i \in V_k$ ($V_k \subseteq V$). Každé elektrické vozidlo reprezentujeme pomocou štvorice

$(a_i, d_i, e_i, \bar{r}_i) \in \mathbb{R}^4$. [1, 6, 12] Obmedzenia, ktoré dodržiavame počas nabíjania elektrických vozidiel sú:

$$0 \leq r_i(k) \leq \bar{r}_i, \quad a_i \leq k < d_i, \quad i \in V \quad (1.1a)$$

$$r_i(k) = 0, \quad k \geq d_i, \quad i \in V \quad (1.1b)$$

$$r_i(k) = 0, \quad k < a_i, \quad i \in V \quad (1.1c)$$

$$\sum_{k=a_i}^{d_i-1} r_i(k) \delta \leq e_i \quad i \in V \quad (1.1d)$$

$$f_j(r_1(k), \dots, r_i(k)) \leq R_j(k) \quad j \in \hat{R}, \quad i \in V \quad (1.1e)$$

Obmedzenie (1.1a) zaručuje, že rýchlosť nabíjania $r_i(k)$ môže byť najvyššou rovnakú ako maximálna rýchlosť nabíjania \bar{r}_i pre elektrické vozidlo i a čas k . Nabíjanie len aktívnych (pripojených) elektrických vozidiel v nabíjacej stanici zabezpečujú obmedzenia (1.1b) a (1.1c). Nabíjanie elektrických vozidiel maximálne ich požadovanou energiou zabezpečuje obmedzenie (1.1d). Obmedzenie (1.1e) používame na zabezpečenie množiny obmedzení \hat{R} infraštruktúry nabíjacej siete. Funkcia f_j je konvexná funkcia, ktorá mapuje vektor $(r_1(k), \dots, r_N(k))$ na agregovanú rýchlosť nabíjania $f_j(r_1(k), \dots, r_N(k))$ ($f_j : \mathbb{R}_+^N \rightarrow \mathbb{R}_+$). Obmedzením (1.1e) zabezpečujeme, že agregovaná rýchlosť $f_j(r_1(k), \dots, r_N(k))$ nabíjania nepresahuje limit infraštruktúry $R_j(k)$ pre každé $j \in \hat{R}$. Obmedzenia infraštruktúry nabíjacej siete $j \in \hat{R}$ sú:

Obmedzenia systémového modelu, ktorý používame rozdelíme takto:

- a) Jednofázové obmedzenia infraštruktúry. Tieto obmedzenia infraštruktúry sa často používajú a sú vhodné len keď sú všetky nabíjačky jednofázové. V tejto práci pracujeme s jedným jednofázovým obmedzením:

$$\sum_{i \in V_k} r_i(k) \leq R, \quad (1.2)$$

$\forall k \in K$. Bližší popis jednofázových obmedzení infraštruktúry je v článku [6]. Asi s nevyváženými trojfázovými by to neslo

- b) Nevyvážené trojfázové obmedzenia infraštruktúry. Popis týchto obmedzení a aj ich odvodenia sa nachádzajú v článku [6].

2 Cieľ práce

Cieľ práce je navrhnuť a overiť model práce agregátora flexibility pre zvolený typ prosumerov. V našom prípade považujeme vlastníkov elektrických vozidiel za prosumerov. Model práce agregátora flexibility je v našom prípade tvorba plánu nabíjania elektrických vozidiel pomocou plánovacích algoritmov. Plán nabíjania má spĺňať požadované vlastnosti:


- a) optimalizuje tok energie. V našom prípade optimalizujeme tok energie tak, aby sme dodali elektrickým vozidlám najväčšie množstvo ich požadovanej energie.
- b) zabezpečuje stabilné dodávky energie. To znamená, že plán nabíjania poskytuje elektrickým vozidlám bez prerušení a bez významných výkyvov v rýchlosti nabíjania.
- c) minimalizuje náklady spotrebiteľov na nabitú energiu.
- d) rešpektuje obmedzenia (1.1a), (1.1b), (1.1c), (1.1d), (1.1e), počas nabíjania elektrických vozidiel.

2.1 Úlohy agregátora flexibility

Agregátor je prostredníkom medzi prosumeri a trhom s elektrinou, tým že združuje flexibilitu od prosumerov, a následne flexibilitu predáva (ako jedna entita) na trhoch s elektrinou. Prosumeri sú odmeňovaní za poskytovanie flexibility agregátorovi. V našom modeli predpokladáme, že prosumeri nie sú odmeňovaní za poskytovanie elektrickej energie agregátorovi.

Rola agregátora zatiaľ nie je presne definovaná. Rola agregátora môže byť určená treťou stranou alebo môže byť určená už účinkujúcim hráčom na trhu s elektrinou, ktorý má napríklad záujem použiť agregátor na doplnujúce veci.

Nezávislý agregátor môže poskytovať jednu službu alebo viac služieb. Medzi služby agregátora patria agregovanie flexibility, dodávky energie spotrebiteľom a vyváženie dopytu a ponuky na trhoch s elektrinou. [2]



Obr. 2.1: Systéme toku energie a aj zisky za energiu. Agregátor (Charging System Operator) kupuje energiu od systémového operátora (utility). Agregátor sa musí rozhodovať: 1. koľko energie od systémového operátora kúpi 2. na rýchlosti nabíjania elektrických vozidiel 3. na distribúcii nákladov za energiu medzi spotrebitľmi elektrických vozidiel. Zdroj obrázka je: [15].

3 Návrh riešenia

V tejto kapitole predstavujeme návrh modelu práce agregátora. Modelom práce agregátora rozumieme spôsob ako agregátor dodáva energiu elektromobilom. Agregátor používa algoritmy v tejto kapitole na riešenie optimalizačného problému [..odkaz].

3.1 Smoothed Least Laxity First.

Algoritmus Smoothed Least Laxity First (skrátene sLLF) vznikol v reakcii na oscilácie v nabíjaní elektrických vozidiel pomocou algoritmu LLF. Oscilácie v nabíjaní elektromobilov skracujú životnosť niektorých baterií elektrických vozidiel (napr. batéria L-ion). Nabíjanie elektrických vozidiel pomocou algoritmu sLLF už neobsahuje oscilácie.

Algoritmus sLLF rozhoduje o aktuálnom pláne nabíjania elektromobilov na základe informácii do aktuálneho času (sLLF je online algoritmus). Algoritmus sLLF pre každý časový krok $k \in K$ maximalizuje minimálnu laxitu a tým zväčšuje rozpätie možných rýchlostí nabíjania. aktuálne nabíjaných elektrických vozidiel pre budúci časový krok v diskretnom modeli. [10]

Laxitou popisujeme v algoritme sLLF flexibilitu (urgenciu) nabíjania. Laxitu $l_i(k)$ elektromobilu i v čase k definujeme takto:

$$l_i(k) = \begin{cases} [d_i - k]^+ - \frac{e_i(k)}{\bar{r}_i} & k \geq a_i, \\ +\infty & k < a_i, \end{cases} \quad (3.1)$$

kde \bar{r}_i je maximálna rýchlosť nabíjania elektromobilu i . $[x]^+$ je projekcia x do množiny nemínusových reálnych čísel R_+ .

Online algoritmus sLLF v každom kroku $k \in K$ rieši optimalizačný problém:

$$\max_{r^{(k)}} \sum_{i \in V_k} \bar{r}_i f(l_i(t+1)) \quad (3.2)$$

$$\text{subject to: (1.1a), (1.1b), (1.1c)} \quad (3.3)$$

Riešením optimalizačného problému (odkaz) je:

$$r_i^*(t) = [\bar{r}_i(L(t) - l_i(t) + 1)]_0^{\min(\bar{r}_i, e_i(t))}, \quad (3.4)$$

$[x]_a^b$ je projekcia na interval

for $k \in K$ do :

$$V_t := \{i \mid a_i \leq t < d_i \wedge e_i(t) > 0\}$$

$$Lax_t := \{l_i(t), i \in V_t\}$$

$$l_L := \min(Lax_t) - 1$$

$$u_L := \max(Lax_t)$$

while $|u_L - l_L| \geq \varepsilon$ do

$$L(t) := \frac{u_L + l_L}{2}$$

if $\sum_{i \in V_t} [\bar{r}_i(L(t) - l_i(t) + 1)]_0^{\min(\bar{r}_i, e_i(t))} \leq P(t)$ then

$$l_L := L(t)$$

else

$$u_L := L(t)$$

$$r^*(t) := \{[\bar{r}_i(L(t) - l_i + 1)]_0^{\min(\bar{r}_i, e_i(t))}, i \in V_t\}$$

Algoritmus 3.1: Pseudokód online algoritmu sLLF.

3.2 Penalised Predictive Control.

for $k \in K$:

$$u_t = \phi_t(p_t) = \min...$$

$$C_t = C_{t-1} + c_t(u_t)$$

$$e_t(i) = e_{t-1}(i) - s_t(i), \forall i \in V_k$$

$$d_t(i) = d_{t-1} - \delta, \forall i \in V_k$$

$$p_{t+1} = \psi^{SAC}(x_t)$$

Algoritmus 3.2: Pseudokód koordinácie agregátora a systémového operátora.

Systémový operátor	
Hyperparameter	Hodnota
$ U $	10
Cenové funkcie c_1, \dots, c_t	UNFINISHED
Operátorova funkcia ϕ	Penalised Predictive Control
Ladiaci parameter β	$[10^3, 10^6]$

Systémový operátor používajúci príliš malé β v PPC algoritme vráti príliš malé signály.

Agregátor	
Hyperparameter	Hodnota
Algoritmus učenia posilňovaním	SAC
Akčný priestor	$[-1, 1]$
Plánovací algoritmus	sLLF [odkaz]
Vstupné dáta	ACN-Data [odkaz]
Rýchlosť učenia	$3 \cdot 10^{-4}$
Počet skrytých vrstiev	UNFINISHED
Zachovanie nelinearity	ReLU
Počet skrytých neurónov pre každú vrstvu	256
Odmenová funkcia	$\sigma_1 = 0.1, \sigma_2 = 0.2, \sigma_3 = 2$

3.2.1 Učenie a testovanie

Agenti sa učia na základe dát z ACN [odkaz...] od 1.11.2018 do 1.12.2019. Testy vykonávame na dátach od 2.11.2019 do 1.1.2020.

- a) Akčný priestor: Akčný priestor Markovského rozhodovacieho procesu používaný PPC algoritmom je $[-1, 1]$ (-1 je dolný limit a 1 je horný limit). Akcie vrátené neuronovými sieťami v SAC algoritme sú následne naškálované na $[0, 1]$ a vydelené ich celkovým súčtom (platí $\sum p_t = 1$).
- b) odmeny:

$$\begin{aligned}
 odmena(\bar{x}_t, p_t) = & H(p_t) + \\
 & \sigma_1 \sum_{i=1}^{N'} ||u_t||_2 - \\
 & \sigma_2 \sum_{i=1}^{N'} \left(I(t = d_i) \left[e_i - \sum_{t=1}^T u_t(i) \right]^+ \right) - \\
 & \sigma_3 \left| \phi_t(p_t) - \sum_{i=1}^{N'} u_t(j) \right|,
 \end{aligned} \tag{3.5}$$

kde $||u_t||_2$ je euklidovská norma u_t .

4 Implementácia

Použili sme Jupyter notebook a programovací jazyk Python na implementáciu, a aj na experimenty. V balíku acn-portal je v programovacom jazyku Python implementovaná základná trieda pre infraštruktúru nabíjacej siete a aj základná trieda pre plánovacie algoritmy.

Ak vytvárame novú infraštruktúru nabíjacej siete alebo plánovací algoritmus, tak vždy nami vytvorené triedy dedia od základných tried v balíku acn-portal.

4.1 Model predictive control

5 Experimenty

V tejto kapitole popisujeme vstupné dáta, nastavenia infraštruktúry nabíjacej siete, ceny nabíjania v čase, ktoré používame v experimentoch. Spomíname aj využité technológie, vďaka ktorým môžeme porovnať naše riešenie s doterajšími riešeniami. Niektoré technológie (5.2.1) sme použili v nami implementovaných algoritmoch.

5.1 Ukážka vstupných dát ACN-Data

```
{
  "_id": "5bc90cb9f9af8b0d7fe77cd2",
  "clusterID": "0039",
  "connectionTime": "Wed, 25 Apr 2018 11:08:04 GMT",
  "disconnectTime": "Wed, 25 Apr 2018 13:20:10 GMT",
  "doneChargingTime": "Wed, 25 Apr 2018 13:21:10 GMT",
  "kWhDelivered": 7.932,
  "sessionID": "2_39_78_362_2018-04-25 11:08:04.400812",
  "siteID": "0002",
  "spaceID": "CA-496",
  "stationID": "2-39-78-362",
  "timezone": "America/Los_Angeles",
  "userID": null,
  "userInputs": null
},
```

Obr. 5.1: Vstupné dáta z nabíjania jedného elektromobilu, ktorý prišiel na nabíjaciu stanicu 25. Apríla 2018. Zdroj: [?].

Obrázok vstupných dát 5.5 obsahuje viacero parametrov, ktoré používateľ musí zadať (napr kWhDelivered), aby mohol nabíjať svoj elektromobil na jednej staníc Caltech, JPL alebo Office001. Iné nabíjacie stanice používajú odlišné vstupné dáta, uvádza sa v [10].

5.2 Využité technológie

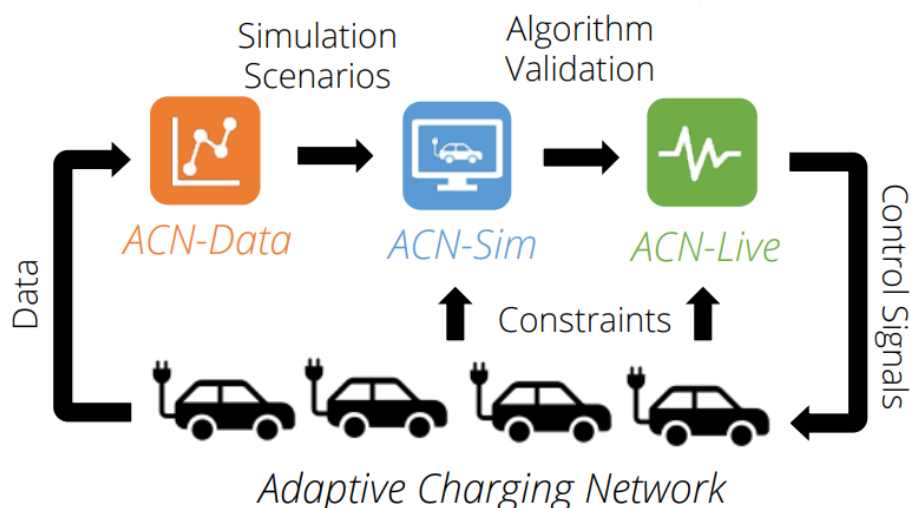
V tejto sekcii spomíname technológie, na ktorých spočíva naša implementácia. Balíky popisujeme hlavne na základe informácií uvedených v ich README súboroch a na základe článku [9]. Podrobný návod, ako vytvoriť algoritmy na základe nasledujúcich balíkov sa nachádza v [9].

5.2.1 Balík acnportal.

Balík acnportal je predovšetkým určený na zrýchlenie výskumu nabíjania veľkého množstva elektrických áut. Balík acnportal umožňuje zrýchlenie výskumu pomocou výskumných nástrojov vyvinutých v Caltechu.

Balík acnportal pozostáva z viacerých komponentov:

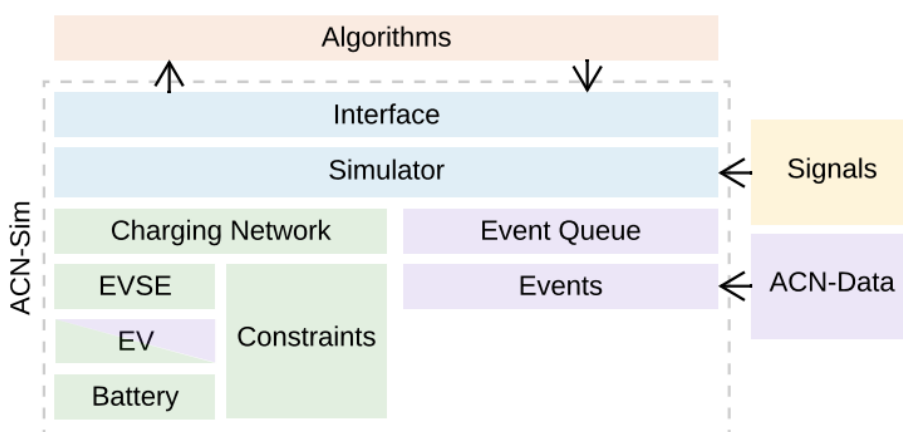
- a) **ACN-Data:** Dáta získané z nabíjacích staníc pre elektromobily, konkrétne zo staníc Caltech, JPL a Office001. Vodiči elektrických vozidiel musia cez mobilnú aplikáciu zadať oskenovaný QR kód nabíjačky a potom zadať približný čas odchodu a množstvo požadovanej energie. Dáta získané od vodičov elektrických vozidiel, a aj dáta slúžiace na konfiguráciu nabíjacej stanice sú uložené v relačnej databáze. Vďaka tejto úložnej vrstve vieme vytvárať vizualizácie pre vodičov elektrických vozidiel a pre sieťových operátorov. Ide hlavne o vizualizáciu stavu systému pre sieťových operátorov a stav nabíjania elektromobilov pre vodičov elektromobilov.
- b) **ACN-Sim:** ACN-Sim je simulátor používaný na testovanie a overovanie funkcionality algoritmov a systémov. Simulátor zabezpečuje realistické prostredie na overovanie funkcionality algoritmov, hlavne pre výskumníkov, ktorý nemajú prístup k reálnym nabíjacím systémom pre nabíjanie elektrických vozidiel.
- c) **ACN-Live:** ACN-Live je hardvér, na ktorom bežia online plánovacie algoritmy na nabíjanie elektrických vozidiel v reálnom čase. Keďže má rovnaké rozhranie ako simulátor ACN-Sim, tak vieme testovať algoritmy implementované v ACN-Sim bez zmeny kódu. [9, 7]



Obr. 5.2: Schéma acnportal. Zdroj obrázka je [9].

Obrázok 5.2 ilustruje interakciu medzi komponentami acnportal. Dáta o nabíjaní získava komponent ACN-Data. O obmedzenia siete a validáciu algoritmov sa stará komponent ACN-Sim. V komponente ACN-Live sa uvádzajú algoritmy z komponentu ACN-Sim do prevádzky. Na takú operáciu netreba meniť kód, lebo ACN-Sim a ACN-Live fungujú cez rovnaké rozhranie. [9, 10]

5.2.2 Architektúra simulátora ACN-Sim



Obr. 5.3: Architektúra simulátora ACN-Sim. Obrázok pochádza z článku [9].

Obrázok 5.3 popisuje architektúru simulátora ACN-Sim. Simulátor ACN-Sim má modulárnu, objektovo orientovanú architektúru. Pod každou krabicou v obrázku 5.3 chápeme základnú triedu, od ktorej môžu dediť nové triedy. Tieto nové triedy môžu napríklad obsahovať nové funkcie.

Simulátor ACN-Sim obsahuje udalosti popisujúce príchod a odchod elektromobilov. Každá udalosť obsahuje informáciu, v ktorom časovom kroku behu simulátora sa má vykonať. V každom časovom kroku behu simulátora sa vykonávajú udalosti v predchádzajúcom časovom kroku alebo udalosti v aktuálnom časovom kroku. Po každej vykonanej udalosti sa spustí plánovací algoritmus a stav infraštruktúry sa aktualizuje. [9]

5.2.3 Balík adacharge.

Balík adacharge obsahuje kontrolný algoritmus MPC, ktorý je schopný riešiť viacero optimalizačných problémov v rámci plánovania nabíjania elektromobilov. Tento MPC algoritmus rieši aj problém, ktorý my riešime, a to problém pridelenia maximálnej energie elektromobilom pri zachovaní obmedzení infraštruktúry pomocou konvexnej optimalizácie. Podrobnejší popis a zdrojový kód balíka Adacharge sa nachádza v [5].

5.2.4 Balík acnportal-experiments.

Účelom balíka acnportal-experiments je zdieľanie experimentov, ktoré pomocou balíka acnportal riešia rôzne vedecké otázky.

Pre tvorbu nových experimentov, ktoré riešia náš problém sú podstatné experimenty 1.2 a 2.1. Tieto experimenty využívajú viacero plánovacích algoritmov a konfigurácii siete. Krátky popis experimentov:

- a) Experiment 1.2: Cieľom experimentu je porovnať viacero konfigurácii infraštruktúry siete a zároveň plánovacie algoritmy. Tento experiment poukazuje na výhody smart sietí. Jednou z výhod smart sietí je, že vedia riešiť problém dodania maximálneho množstva energie pri zachovaní obmedzení infraštruktúry siete.
- b) Experiment 2.1: Cieľom experimentu je porovnať výkonnosť týchto plánovacích algoritmov: round robin, earliest deadline first, least laxity first. Jedným z výsledkov experimentu je koľko percent požadovanej energie dodá elektromobilom každý algoritmus.

5.2.5 Balík stable-baselines3.

Balík stable-baselines3 vytvorili za účelom implementovania viacerých spolačlivých algoritmov učenia posilňovaním (vývojári otestovali výkonnosť všetkých algoritmov). My používame algoritmus SAC z balíka stable-baselines3 na učenie a testovanie algoritmu [odkaz...]. Balík stable-baselines3 obsahuje podrobnú dokumentáciu a aj obsiahlu funkcionálnu.

Podrobnejší popis a výsledky experimentov vieme nájsť v [4].

5.3 Konfigurácia a obmedzenia nabíjacích sietí



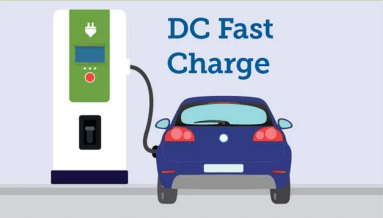
V tejto sekcii uvádzame jednotlivé konfigurácie a obmedzenia nabíjacích sietí, na ktorých navrhujeme a overujeme model agregátora flexibility. Vysvetľujeme postupne rôzne typy nabíjania, obmedzenia sietí atď.

5.3.1 Typy nabíjania.

Všetky experimenty, ktoré vykonávame používajú nabíjanie typu AC level 1 alebo nabíjanie typu AC level 2. Nabíjanie AC level 1 je predovšetkým určené pre vlastníkov elektrických vozidiel, ktorí ich chcú nabíjať dlhodobo (napríklad cez noc). Rýchlosť nabíjania typu AC level 1 je 1.4 kWh až do 1.9 kWh energie. Nabíjanie typu AC level 1 dokáže úplne nabiť batériu elektrického vozidla v rozmedzí od 8 do 20 hodín (v závislosti od kapacity batérie a typu batérie elektrického vozidla).

Typ nabíjania AC level 2 je rýchlejší typ nabíjania ako AC level 1. Rýchlosť nabíjania pri AC level 2 je od 2.5 kWh do 19.2 kWh. Počas dňa môže viacero spotrebiteľov nabíjať vďaka takejto rýchlosti nabíjania.

Pri takejto rýchlosti nabíjania elektrických vozidiel sa môže vystriedať pri nabíjaní počas dňa viacero spotrebiteľov. Nevýhodou typu nabíjania AC level 2 je, že vyžaduje väčšie náklady na inštaláciu. [14, 16]

KNOW YOUR EV CHARGING STATIONS		
 <p>AC Level One</p> <p>VOLTAGE 120V 1-Phase AC</p> <p>AMPS 12–16 Amps</p> <p>CHARGING LOAD 1.4–1.9 kW</p> <p>CHARGING TIME 3–5 Miles per Hour</p>	 <p>AC Level Two</p> <p>VOLTAGE 208V or 240V 1-Phase AC</p> <p>AMPS 12–80 Amps (Typ. 32 Amps)</p> <p>CHARGING LOAD 2.5–19.2 kW (Typ. 6.6 kW)</p> <p>CHARGING TIME 12–60 Miles per Hour</p>	 <p>DC Fast Charge</p> <p>VOLTAGE 208V or 480V 3-Phase AC</p> <p>AMPS >100 Amps</p> <p>CHARGING LOAD 50–350 kW</p> <p>CHARGING TIME 60–80 Miles in 20 Minutes</p>

Obr. 5.4: Všetky dnešné typy nabíjania elektromobilov s príslušnými údajmi o rýchlosti nabíjania a kapacite kábla. Zdroj obrázka: [16].

5.3.2 Infraštruktúra nabíjacej stanice.

Simulátor ACN-Sim využíva inštancie triedy `ChargingNetwork` na modelovanie infraštruktúry nabíjacej siete. To znamená, že trieda `ChargingNetwork` modeluje nabíjačky (napríklad ich počet, typ nabíjačiek atď), transformátor (určený na prenos energie v nabíjacej sieti), prepínacie panely a káble.

Na zmenu alebo rozšírenie funkcionality triedy `ChargingNetwork` je nutné vytvoriť novú triedu, ktorá dedí od triedy `ChargingNetwork`. Takto bola vytvorená trieda `StochasticNetwork`, ktorá sa odlišuje od triedy `ChargingNetwork` v pridelovaní nabíjačiek prichádzajúcim elektromobilom. Popis, ako sa pridelujú nabíjačky elektromobilom:

ChargingNetwork

V tomto type nabíjacej siete je každý prichádzajúci elektromobil priradený vopred priradený určenej nabíjačke v nabíjacej sieti.

StochasticNetwork

Tento typ nabíjacej siete prideluje každému prichádzajúcemu elektromobilu voľnú nabíjačku náhodne. V prípade, keď príde elektromobil do nabíjacej stanice a žiadna nabíjačka v nabíjacej stanici nie je voľná, tak elektromobil pridá do koniec čakacieho radu. Potom v okamihu, keď sa nabíjačka uvoľní, tak sa priradí prvému elektromobilu v čakacom rade (ktoré sa z čakacieho radu odstráni).

Typ nabíjacej siete `StochasticNetwork` je viac vhodný než typ nabíjacej siete `ChargingNetwork` hlavne pre uplatnenie v praxi, ale aj v pri generovaní udalostí zo štatistických modelov. [9]

UNFINISHED

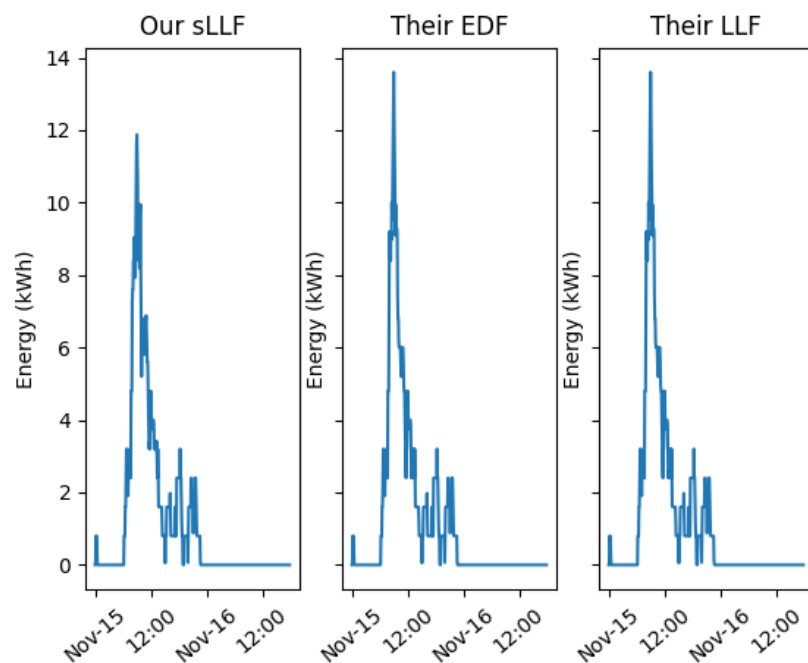
5.4 Prvý experiment

5.4.1 Vstupné dáta

Vstupné dáta do plánovacích algoritmov, ktoré porovnávame, sú údaje (popísané v sekcii odkaz) o aktívnych elektrických vozidlách. Tieto údaje generujeme z `ACN-Data` pomocou pythonovského rozhrania.

5.4.2 Hárđverové nastavenia

5.4.3 Výsledky



Obr. 5.5:

Algoritmus	sLLF	EDF	LLF
Pomer dodanej energie (v %)	100	100	100
Množstvo dodanej energie	617.73	617.73	617.73
Cena energie	47.14	47.08	47.08
Poplatok za výkon	2210.17	2531.23	2531.23
Celková cena energie	2257.31	2578.31	2578.31
\$/kWh	3.65	4.17	4.17

5.5 Druhý experiment

Cieľom druhého experimentu je porovnať výkonnosť online algoritmov založených na triedení pri riešení formulovaného problému (odkaz).

5.5.1 Vstupné dáta

Vstupné dáta o príchodoch elektromobilov (plugin udalosti) načítavame z nabíjacej stanice Caltech. Ako začiatok príchodov elektromobilov sme nastavili 9. September 2018 a ako koniec príchodov elektromobilov sme nastavili 11. Septembra 2018. Dokopy sme dostali

5.5.2 Nastavenia

Používame obmedzenia a nabíjačky nabíjacej stanice Caltech ACN. Pre jednoduchosť sme nastavili, aby nabíjačky boli typu BASICEVSE. Obmedzenia pre nevyváženú trofázovú infraštruktúru siete zostali nezmenené. Tarify, ktoré používame sa nazývajú *sce_tou_ev_4_march_2019*.

5.5.3 Výsledky

5.6 Tretí experiment

Záver

Literatúra

- [1] Niangjun Chen, Christian Kurniawan, Yorie Nakahira, Lijun Chen, and Steven H. Low. Smoothed least-laxity-first algorithm for ev charging, 2021.
- [2] Pedro Crespo del Granado, Jayaprakash Rajasekharan, Surya Venkatesh Pandiyan, Asgeir Tomasgard, Güray Kara, Hossein Farahmand, and Stefan Jaehnert. Flexibility characterization, aggregation, and market design trends with a high share of renewables: a review. *Current Sustainable/Renewable Energy Reports*, 10(1):12–21, Mar 2023.
- [3] International Energy Agency (IEA). Global ev outlook 2023. <https://www.iea.org/reports/global-ev-outlook-2023>. Accessed: April 2024.
- [4] Z. J. Lee and S. Sharma. acnportal-experiments. <https://github.com/caltech-netlab/acnportal-experiments>, November 2020. Accessed: December 2023.
- [5] Z. J. Lee and S. Sharma. adacharge. <https://github.com/caltech-netlab/adacharge>, November 2020. Accessed: December 2023.
- [6] Zachary J. Lee, Daniel Chang, Cheng Jin, George S. Lee, Rand Lee, Ted Lee, and Steven H. Low. Large-scale adaptive electric vehicle charging. *2018 IEEE International Conference on Communications, Control, and Computing Technologies for Smart Grids (SmartGridComm)*, pages 1–7, 2018.
- [7] Zachary J. Lee, George Lee, Ted Lee, Cheng Jin, Rand Lee, Zhi Low, Daniel Chang, Christine Ortega, and Steven H. Low. Adaptive charging networks: A framework for smart electric vehicle charging, 2020.
- [8] Zachary J. Lee, Tongxin Li, and Steven H. Low. Acn-data: Analysis and applications of an open ev charging dataset. In *Proceedings of the Tenth ACM International Conference on Future Energy Systems, e-Energy '19*, page 139–149, New York, NY, USA, 2019. Association for Computing Machinery.
- [9] Zachary J. Lee, Sunash Sharma, Daniel Johansson, and Steven H. Low. Acn-sim: An open-source simulator for data-driven electric vehicle charging research, 2021.

- [10] Zachary Jordan Lee. *The Adaptive Charging Network Research Portal: Systems, Tools, and Algorithms*. Dissertation, California Institute of Technology, 2021.
- [11] Sichen Li, Weihao Hu, Di Cao, Tomislav Dragicevic, Qi Huang, Z. Chen, and F. Blaabjerg. Electric vehicle charging management based on deep reinforcement learning. *Journal of Modern Power Systems and Clean Energy*, 10:719–730, 05 2022.
- [12] Tongxin Li, Bo Sun, Yue Chen, Zixin Ye, Steven H. Low, and Adam Wierman. Learning-based predictive control via real-time aggregate flexibility. *IEEE Transactions on Smart Grid*, 12(6):4897–4913, November 2021.
- [13] Wanrong Tang, Suzhi Bi, Ying Jun, and Minglong Zhang. Online charging scheduling algorithms of electric vehicles in smart grid: An overview. *IEEE Communications Magazine*, 54, 08 2016.
- [14] umini. Different types of ev charging; level 1, level 2, and dc fast charging, 04 2023.
- [15] Steven H. Low Zachary J. Lee, John Z.F. Pang. Pricing ev charging service with demand charge. <https://resnick.caltech.edu/documents/17395/RSIonline-RH-Lee-Z-SEPT-2020.pdf>, 2020. Accessed: 3rd December, 2023.
- [16] ZDWL. Ev charger levels. <https://zdwl-tec.com/news/ev-charger-levels/>, 2023. Accessed: 3rd December, 2023.
- [17] Guanchen Zhang, Shaoqing Tim Tan, and G. Wang. Real-time smart charging of electric vehicles for demand charge reduction at non-residential sites. *IEEE Transactions on Smart Grid*, 9:4027–4037, 2018.

Príloha A: obsah elektronickej prílohy

Príloha B: Používateľská príručka