

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

PODPORA INTELIGENTNÉHO RIADENIA
ENERGETICKÝCH SIETÍ
DIPLOMOVÁ PRÁCA

2023

BC. OMAR AL-SHAFE'I

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

PODPORA INTELIGENTNÉHO RIADENIA
ENERGETICKÝCH SIETÍ
DIPLOMOVÁ PRÁCA

Študijný program: Informatika
Študijný odbor: Aplikovaná informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: prof. RNDr. Mária Lucká, PhD.

Bratislava, 2023
Bc. Omar Al-Shafe'i



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Omar Al-Shafe'i
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Podpora inteligentného riadenia energetických sietí
Support for intelligent management of smart energy networks

Anotácia: Stabilita inteligentnej energetickej siete a zabezpečenie dodávok elektrickej energie môže byť potenciálne narušená integráciou obnoviteľných zdrojov energie (napr. fotovoltických panelov), veľkých úložísk energie (batérií), ale aj významným rozvojom elektromobility. Tieto nové prvky sa v súčasnosti v čoraz väčšej miere stávajú súčasťou moderných inteligentných energetických sietí a preto ich integrácia do celej sústavy sa stala mimoriadne dôležitou. Pôvodne jednosmerná sieť, kde sa energia od veľkých výrobcov elektriny dodávala spotrebiteľom, sa postupne mení na obojsmernú sieť, v ktorej sa mnohí odberatelia - vďaka obnoviteľným zdrojom - stávajú súčasne aj drobnými výrobcami – prosumeri. Kvôli garancii stability celej sústavy a zabezpečeniu minimálnej ceny bolo potrebné vytvoriť tzv. agregátorov flexibility, ktorým účastníci siete môžu poskytnúť svoju flexibilitu. Pod flexibilitou pritom rozumieme práva (1) na odber vyrobenej alebo uskladnenej elektrickej energie (napr. z fotovoltiky, batérie alebo elektromobilu) v určitom čase a (2) obmedzenie spotreby (napr. vypnutie kúrenia). Navrhnete a overte model práce agregátora flexibility, ktorý vďaka inteligentným algoritmom a dátovej analýze dokáže optimalizovať tok energie, zabezpečiť stabilné dodávky energie a minimalizovať náklady spotrebiteľov. Svoje riešenie obmedzte pre vybraný typ prosumerov/spotrebiteľov. Použite pritom vhodné optimalizačné metódy, predovšetkým metódy strojového učenia. Svoje riešenie implementujte a porovnajte s existujúcimi riešeniami na dostupných dátach.

Literatúra:

1. Li, T., Sun, B., Chen, Y., Ye, Z., Low, S. H., & Wierman, A. (2020). Real-time Aggregate Flexibility via Reinforcement Learning. 1–17. <http://arxiv.org/abs/2012.11261>
2. Fernando Lezama, Joao Soares, Bruno Canizes, Zita Vale: Flexibility management model of home appliances to support DSO requests in smart grids, Sustainable Cities and Society, Volume 55, 2020, ISSN 2210-6707, <https://doi.org/10.1016/j.scs.2020.102048>
3. Tongxin Li and Bo Sun and Yue Chen and Zixin Ye and Steven H. Low and Adam Wierman: Learning-Based Predictive Control via Real-Time Aggregate Flexibility, IEEE Transactions on Smart Grid, 12 (6), 2021, 97–4913, <https://doi.org/10.1109/2Ftsg.2021.3094719>.



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

4. Steve Wattam: Artificial intelligence and machine learning approaches to energy demand-side response: A systematic review, Renewable and Sustainable Energy Reviews, Volume 130, 2020, 109899, ISSN 1364-0321, <https://doi.org/10.1016/j.rser.2020.109899>.

Vedúci: prof. RNDr. Mária Lucká, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.
Dátum zadania: 13.12.2022

Dátum schválenia: 13.12.2022

prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

.....
študent

.....
vedúci práce

Pod'akovanie: Tu môžete pod'akovať školiteľ ovi, prípadne ďalším osobám, ktoré vám s prácou nejako pomohli, poradili, poskytli dáta a podobne.

Abstrakt

Slovenský abstrakt v rozsahu 100-500 slov, jeden odstavec. Abstrakt stručne sumarizuje výsledky práce. Mal by byť pochopiteľný pre bežného informatika. Nemal by teda využívať skratky, termíny alebo označenie zavedené v práci, okrem tých, ktoré sú všeobecne známe.

Kľúčové slová: jedno, druhé, tretie (prípadne štvrté, piate)

Abstract

Abstract in the English language (translation of the abstract in the Slovak language).

Keywords:

Obsah

Úvod	1
1 Východiská	2
1.1 Technologické východiská	2
1.1.1 Knižnica numpy	2
1.1.2 Knižnica scipy	2
1.1.3 Knižnica pytorch	2
1.2 Teoretické východiská	2
2 Návrh riešenia	5
2.1 Least Laxity First	5
3 Implementácia	6
3.1 Vstupné dáta	6
Záver	8
Príloha A	10
Príloha B	11

Zoznam obrázkov

3.1	Dáta z Caltech adaptívnej nabíjacej siete.	6
3.2	Dáta z JPL adaptívnej nabíjacej siete.	7

Zoznam tabuliek

Úvod

Problematika zabezpečenia stabilných dodávok elektrickej energie pri používaní obnoviteľných zdrojov sa stáva čoraz dôležitejšou. Pomocou dobrého modelu vieme zabezpečiť komunikáciu medzi systémovým operátorom a agregátorom tak, aby fluktuácie elektrickej energie a náklady boli čo najmenšie. Cieľom tejto práce je implementovať komunikáciu medzi agregátorom a systémovým operátorom pomocou modelu PPC, tak aby sme vyriešili optimalizačný problém, čo zabezpečí, že používatelia budú mať stabilný prísun energie za minimálnu cenu. Bežne sa už na túto úlohu používal MPC už skôr, ale model PPC vie lepšie vyriešiť komunikáciu a aj optimalizačný problém. Model PPC je lepší než model MPC vo viacerých oblastiach, ale spomeňme tie najdôležitejšie - systémovému operátorovi stačí vedieť MEF (t. j. flexibilitu), vôbec nemusí vedieť o stavoch a požiadavkách jednotlivých spotrebiteľov. Po druhé, systémový operátor vie znížiť náklady spotrebiteľov elektrickej energie lepšie v modeli PPC než v modeli MPC.

Implementácia PPC sa od implementácie MPC veľmi nelíši - jediný rozdiel je v tom, že PPC používa MEF na sprostredkovanie požiadaviek spotrebiteľov systémovému operátorovi. MEF vieme vypočítať pomocou hlbokého učenia. Hlboké učenie používame najmä preto, že výpočet MEF môže byť výpočtovo náročný a vďaka hlbokému učeniu ho vieme aproximovať. Danú flexibilitu následne použijeme ako penalizujúci prvok v našom PPC systéme. Tento náš model naprogramujeme v programovacom jazyku Python. [5]

V prvej kapitole vysvetlíjeme teoretické pojmy a knižnice, na ktoré sa odvolávame v ďalších kapitolách.

V druhej kapitole uvádzame náš návrh riešenia, ktorý ako sme už uviedli, sa zakladá na PPC modeli.

V tretej kapitole vysvetlíjeme spôsob našej implementácie, jednotlivé metódy a aj kód.

1 Východiská

V tejto kapitole spomíname technologické východiská, ktoré sme využili pri implementácii. Rozoberáme ale aj teoretické východiská, pomocou ktorých definujeme nové pojmy.

1.1 Technologické východiská

V tejto sekcii spomíname knižnice, frameworky a ďalšie technológie, ktoré sme pri implementácii použili.

1.1.1 Knižnica numpy

Knižnica numpy rozširuje možnosti v oblasti práce s poľami. V knižnici numpy sú 2 hlavné objekty: ndarray a ufunc. Pomocou objektu ndarray vieme definovať N-dimenzionálne pole a pomocou ufunc vieme definovať matematické funkcie. Každé pole objektu ndarray obsahuje homogénnu kolekciu prvkov. Navyše vieme pomocou knižnice numpy zjednodušiť zložité cykly pomocou operácií `numpy.dot` alebo `numpy.outer`, čo značne zlepšuje časovú zložitosť programu. [7]

1.1.2 Knižnica scipy

1.1.3 Knižnica pytorch

Knižnica pytorch bola založená facebookovou skupinou študujúcu umelú inteligenciu. Hlavným cieľom vývoja tejto knižnice bolo zjednodušiť tvorbu a vývoj modelov. Knižnica pytorch je založená na knižnici torch a používa sa v programovacom jazyku Python. Pytorch je knižnica určená na písanie dynamických modelov. Z toho dôvodu sa často používa na veľké konštrukcie hlbokého učenia. [6]

1.2 Teoretické východiská

Definície a vety a notácia, ktoré uvádzame ak nie je bližšie špecifikovaný zdroj, tak pochádzajú z článkov [5] a [4].

Parametre spotrebiteľa. Každému spotrebiteľovi $j = 1, \dots, N$ je pridelená štvorica dát $(a(j), d(j), e(j), r(j)) \in R^4$. Parameter $a(j)$ znamená čas príchodu a parameter $d(j)$ je čas odchodu. Obe premenné sa normalizujú. Parameter $e(j)$ označuje množstvo požadovanej energie v jednotkách kWh a $r(j)$ je maximálne množstvo nabíjacej energie.

Rozhodnutie agregátora. Rozhodnutie agregátora v čase t pre všetkých spotrebiteľov označujeme s_t . Premenná s_t obsahuje pridelenie energie pre každého spotrebiteľa v čase t na základe nejakého triediaceho algoritmu. Nech π_t je použitý triediaci algoritmus (napr. Least Laxity First, Early Deadline First) v čase t . Potom premennú s_t vypočítame takto:

$$s_t = \pi_t(u_t), \quad (1.1)$$

kde $u_t \in U$ je úroveň výkonu agregátnej rozvodne v čase t .

Stav agregátora. Stav agregátora v čase t označujeme x_t . Hodnotu premennej x_t zistíme takto:

$$x_t = \{(d_t(j), e_t(j) : a(j) < t < d(j)), j = 1, \dots, N\}, \quad (1.2)$$

kde $e_t(j)$ je zostávajúca požadovaná energia a $d_t(j)$ je zostávajúci čas na nabíjanie v čase t .

Prechodové funkcie. Každé rozhodnutie $s_t(j) \in R$ agregátora v čase t pre spotrebiteľa j zmení stav agregátora. Keď sa zmena aplikuje na všetkých spotrebiteľov stav agregátora sa zmení z x_t na x_{t+1} . Aplikujeme dve prechodové funkcie na $e_t(j)$ a na $d_t(j)$ takto:

$$e_t(j) = e_{t-1}(j) - s_t(j), \quad (1.3)$$

$$d_t(j) = d_{t-1}(j) - \Delta, \quad (1.4)$$

kde časový interval Δ je 12 minút. Predpokladáme, že nenastane žiadna strata energie. Tým dostaneme nový stav:

$$x_{t+1} = f(x_t \in X_t). \quad (1.5)$$

Podmienky pre rozhodnutie agregátora. Podmienky, ktoré by mali byť rozhodnutím agregátora splnené sú:

$$s_t(j) = 0, \text{ ak } t < a(j) \text{ alebo } t > d(j), j = 1, \dots, N, \quad (1.6)$$

$$\sum_{j=1}^N s_t(j) = u_t, j = 1, \dots, N, \quad (1.7)$$

$$\sum_{t=1}^T s_t(j) = e(j), t = 1, \dots, T, \quad (1.8)$$

$$0 \leq s_t(j) \leq r(j), t = 1, \dots, T. \quad (1.9)$$

Obe podmienky 1.6 a 1.9 vždy platia. Dalšie uvedené podmienky nemusia nutne platiť.

MPE. Chyba mean percentage error, v skratke MPE je pomer nedodanej energie k dodanej energii (porušenie podmienky 1.8). Počíta sa vzorcom:

$$MPE = 1 - \sum_{k=1}^L \sum_{t=1}^T \sum_{j=1}^N \frac{s_t(j)}{\sum_{j=1}^N e_j}, \quad (1.10)$$

kde MPE nadobúda hodnoty z intervalu $[0, 1]$.

2 Návrh riešenia

V tejto kapitole vysvetlíjeme ako prebieha komunikácia medzi agregátorom a systémovým operátorom v našom navrhovanom modeli. Taktiež rozoberáme, ako prebieha triedenie a iné operácie, ktoré sa vykonávajú v našom navrhovanom modeli.

2.1 Least Laxity First

Náš triediaci algoritmus sa nazýva Least Laxity First (ďalej len LLF). LLF pre každého používateľa j vypočíta jeho laxitu použitím vzorca

$$laxita = d_t(j) - \frac{e_t(j)}{r(j)}, \quad (2.1)$$

kde $d_t(j)$ je zostávajúci čas na nabíjanie a $e_t(j)$ je zostávajúca požadovaná energia v čase t). Na základe vyššie vypočítanej laxity utriedi používateľov do prioritného frontu, kde používatelia s najnižšou laxitou budú preferovaní.

Potom, keď už každý spotrebiteľ má vypočítanú vlastnú laxitu, tak algoritmus pridá elektrickú energiu (aj nulovú) v každom čase t spotrebiteľom s najmenšou laxitou po najväčšiu laxitu.

3 Implementácia

V tejto kapitole vysvetľujeme a popisujeme vstupné a výstupné dáta a aj kód implementovaného programu. Vlastnosti vstupných dát, ich pôvod a iné veci, ktoré spomíname sa nachádzajú v článku [4]. Odkaz, pomocou ktorého je možné vstupné dáta získať sa tiež nachádza v článku [4].

3.1 Vstupné dáta

Dáta, z ktoré čerpáme pochádzajú z 2 adaptívnych nabíjaciích sietí (anglická skratka je ACN), ktoré sa nachádzajú v Kalifornii. Nabíjacia sieť Caltechu je dostupná verejnosti, zatiaľ čo nabíjaciu sieť JPL môžu používať len zamestnanci.

```
{
  {
    "_id": "5bc90cb9f9af8b0d7fe77cd2",
    "clusterID": "0039",
    "connectionTime": "Wed, 25 Apr 2018 11:08:04 GMT",
    "disconnectTime": "Wed, 25 Apr 2018 13:20:10 GMT",
    "doneChargingTime": "Wed, 25 Apr 2018 13:21:10 GMT",
    "kWhDelivered": 7.932,
    "sessionID": "2_39_78_362_2018-04-25 11:08:04.400812",
    "siteID": "0002",
    "spaceID": "CA-496",
    "stationID": "2-39-78-362",
    "timezone": "America/Los_Angeles",
    "userID": null,
    "userInputs": null
  },
}
```

Obr. 3.1: Dáta z Caltech adaptívnej nabíjacej siete.

Kde pre nás najpodstatnejšie premenné sú `connectionTime`, `disconnectTime` a `kWhDelivered`. Tieto premenné reprezentujeme pomocou trojice $(a(j), d(j), e(j))$.


```
{
  "_id": "5c36621bf9af8b4639a8e0b9",
  "clusterID": "0001",
  "connectionTime": "Wed, 05 Sep 2018 13:10:14 GMT",
  "disconnectTime": "Wed, 05 Sep 2018 22:21:44 GMT",
  "doneChargingTime": null,
  "kWhDelivered": 13.282,
  "sessionID": "1_1_179_798_2018-09-05 13:10:13.879377",
  "siteID": "0001",
  "spaceID": "AG-3F18",
  "stationID": "1-1-179-798",
  "timezone": "America/Los_Angeles",
  "userID": "000000334",
  "userInputs": [
    {
      "WhPerMile": 400,
      "kWhRequested": 20.0,
      "milesRequested": 50,
      "minutesAvailable": 569,
      "modifiedAt": "Wed, 05 Sep 2018 13:10:45 GMT",
      "paymentRequired": true,
      "requestedDeparture": "Wed, 05 Sep 2018 22:39:14 GMT",
      "userID": 334
    }
  ],
}
```

Obr. 3.2: Dáta z JPL adaptívnej nabíjacej siete.

Záver

Literatúra

- [1] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In Jennifer Dy and Andreas Krause, editors, *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1861–1870. PMLR, 10–15 Jul 2018.
- [2] Diederik Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *International Conference on Learning Representations*, 12 2014.
- [3] Zachary J. Lee, Daniel Johansson, and Steven H. Low. Acn-sim: An open-source simulator for data-driven electric vehicle charging research. In *2019 IEEE International Conference on Communications, Control, and Computing Technologies for Smart Grids (SmartGridComm)*, pages 1–6, 2019.
- [4] Zachary J. Lee, Tongxin Li, and Steven H. Low. Acn-data: Analysis and applications of an open ev charging dataset. In *Proceedings of the Tenth ACM International Conference on Future Energy Systems, e-Energy '19*, page 139–149, New York, NY, USA, 2019. Association for Computing Machinery.
- [5] Tongxin Li, Bo Sun, Yue Chen, Zixin Ye, Steven H. Low, and Adam Wierman. Learning-based predictive control via real-time aggregate flexibility. *IEEE Transactions on Smart Grid*, 12(6):4897–4913, nov 2021.
- [6] P. Mishra. *PyTorch Recipes: A Problem-solution Approach*. Distributed to the Book trade worldwide by Springer Science+Business Media New York, 2019.
- [7] Travis E Oliphant et al. *A guide to NumPy*, volume 1. Trelgol Publishing USA, 2006.

Príloha A: obsah elektronickej prílohy

Príloha B: Používateľská príručka