

Podpora inteligentného riadenia energetických sietí

Diplomová práca

Bc. Omar Al-Shafe'i

prof. RNDr. Mária Lucká, PhD.

Fakulta matematiky, fyziky a informatiky

8. mája 2023

Obsah

- 1 Úvod
- 2 Teoretické východiská
- 3 Technologické východiská
- 4 Implementácia
 - Vstupné dáta z Caltechu
 - Vstupné dáta z JPL
 - Prototyp
- 5 Literatúra
 - Hlavné zdroje
 - Vedľajšie zdroje
- 6 Záver

Oblasť práce

- S rozvojom obnoviteľných zdrojov energie ako napríklad fotovoltických panelov, veľkých úložísk energie, ale aj s rozvojom elektromobility sa stabilita stáva čoraz dôležitejšou.


Cieľ práce

- Cieľom tejto práce je implementovať model práce agregátora flexibility. Výsledný model by mal viesť zabezpečiť stabilné dodávky energie (napr. pre elektronické autá) a minimalizovať náklady spotrebiteľov vyriešením optimalizačného problému. Také riešenie treba následne porovnať s inými existujúcimi riešeniami.
- Model implementujeme na základe článku Li, T., Sun, B., Chen, Y., Ye, Z., Low, S. H., Wierman, A. (2020). Real-time Aggregate Flexibility via Reinforcement Learning. 1–17.
<http://arxiv.org/abs/2012.11261>

Teoretické východiská

Čo je to Penalized Predictive Control (PPC)?

- Je to variant nelineárneho model predictive control (MPC).
- Narozdiel od MPC, neposiela požiadavky systémovému operátorovi priamo od spotrebiteľov, ale namiesto toho posiela len flexibilitu.
- Vie vyriešiť náš optimalizačný problém lepšie než štandardný MPC.



Obr. 1: Systémový model z článku Li, T., Sun, B., Chen, Y., Ye, Z., Low, S. H., Wierman, A. (2020). Real-time Aggregate Flexibility via Reinforcement Learning. 1–17.

Technologické východiská

Programovací jazyk

- Python

Použité knižnice/frameworky

- numpy: Knižnica obsahuje metódy pre prácu s poľami a maticami. Knižnica je veľmi užitočná na optimalizovanie viacerých for cyklov použitím matíc a maticových operácií.
- pytorch: Knižnica obsahuje užitočné nástroje na tvorbu neurónových sietí a následnú prácu s nimi.
- time: Knižnica, pomocou ktorej vieme normalizovať čas.
- OpenAI Gym: Knižnica, pomocou ktorej vieme vyvíjať a porovnávať rôzne algoritmy hlbokého učenia.

Implementácia

Vstupné dáta z Caltechu

```
{
  "_id": "5bc90cb9f9af8b0d7fe77cd2",
  "clusterID": "0039",
  "connectionTime": "Wed, 25 Apr 2018 11:08:04 GMT",
  "disconnectTime": "Wed, 25 Apr 2018 13:20:10 GMT",
  "doneChargingTime": "Wed, 25 Apr 2018 13:21:10 GMT",
  "kWhDelivered": 7.932,
  "sessionID": "2_39_78_362_2018-04-25 11:08:04.400812",
  "siteID": "0002",
  "spaceID": "CA-496",
  "stationID": "2-39-78-362",
  "timezone": "America/Los_Angeles",
  "userID": null,
  "userInputs": null
},
```

Obr. 2: Vstupné dáta z Caltech nabíjacej siete.

Notácia

Premennú `connectionTime` označujeme $\mathbf{a}(j)$. Premennú `disconnectTime` označujeme $\mathbf{d}(j)$. Premennú `kWhDelivered` označujeme $\mathbf{e}(j)$. Každý používateľ j má definovanú trojicu $(\mathbf{a}(j), \mathbf{d}(j), \mathbf{e}(j))$.

Implementácia

Vstupné dáta z JPL

```
{
  "_id": "5c36621bf9af8b4639a8e0b9",
  "clusterID": "0001",
  "connectionTime": "Wed, 05 Sep 2018 13:10:14 GMT",
  "disconnectTime": "Wed, 05 Sep 2018 22:21:44 GMT",
  "doneChargingTime": null,
  "kWhDelivered": 13.282,
  "sessionID": "1_1_179_798_2018-09-05 13:10:13.879377",
  "siteID": "0001",
  "spaceID": "AG-3F18",
  "stationID": "1-1-179-798",
  "timezone": "America/Los_Angeles",
  "userID": "000000334",
  "userInputs": [
    {
      "WhPerMile": 400,
      "kWhRequested": 20.0,
      "milesRequested": 50,
      "minutesAvailable": 569,
      "modifiedAt": "Wed, 05 Sep 2018 13:10:45 GMT",
      "paymentRequired": true,
      "requestedDeparture": "Wed, 05 Sep 2018 22:39:14 GMT",
      "userID": 334
    }
  ]
},
```

Obr. 3: Vstupné dáta z JPL nabíjacej siete.

Prototyp

Least Laxity First (LLF)

Triediaci algoritmus LLF, ktorý vypočíta pre každého používateľa jeho laxitu:

$$laxity = d_t(j) - \frac{e_t(j)}{r(j)}, \quad (1)$$

kde $d_t(j)$ je zostávajúci čas na nabíjanie, $e_t(j)$ je zostávajúca požadovaná energia a $r(j)$ je maximálne množstvo energie na nabíjanie. Následne LLF prideliť energiu (aj nulovú) používateľom v poradí od najnižšej laxity po najvyššiu proces v každom čase t .

Výstup

- Počet nabíjaných elektrických áut v každom čase t .
- Náklady na nabíjanie elektrických áut v každom čase t .
- Chyba Mean Percentage Error (MPE), ktorá nám udáva pomer nedodanej energie k dodanej energii ($0 \leq MPE \leq 1$). Použitím knižnice numpy vieme výpočet MPE veľmi zefektívniť.

Hlavné zdroje

- Li, T., Sun, B., Chen, Y., Ye, Z., Low, S. H., Wierman, A. (2020). Real-time Aggregate Flexibility via Reinforcement Learning. 1–17. <http://arxiv.org/abs/2012.11261>
- Zachary J. Lee, Tongxin Li, and Steven H. Low. 2019. ACN-Data: Analysis and Applications of an Open EV Charging Dataset. In Proceedings of the Tenth ACM International Conference on Future Energy Systems (e-Energy '19). Association for Computing Machinery, New York, NY, USA, 139–149. <https://doi.org/10.1145/3307772.3328313>

Vedľajšie zdroje

- Z. J. Lee, D. Johansson and S. H. Low, "ACN-Sim: An Open-Source Simulator for Data-Driven Electric Vehicle Charging Research," 2019 IEEE International Conference on Communications, Control, and Computing Technologies for Smart Grids (SmartGridComm), Beijing, China, 2019, pp. 1-6, doi: 10.1109/SmartGridComm.2019.8909765.
- Kingma, Diederik Ba, Jimmy. (2014). Adam: A Method for Stochastic Optimization. International Conference on Learning Representations.
- Haarnoja, Tuomas, et al. "Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor." International conference on machine learning. PMLR, 2018.

Dosiahnuté ciele a prínosy

Dosiahnuté ciele

- Vytvorili sme model, ktorý zabezpečuje stabilné dodávky energie a minimalizuje náklady spotrebiteľov naivným spôsobom.

Prínosy práce

- Implementácia modelu, pomocou ktorého vie nabíjacia stanica priradovať energiu s minimálnou cenou jednotlivým používateľom v čase t .

Ďakujem za pozornosť